

## 《人类专家对照组实验记录协议 (Human Expert Baseline Protocol)》

### 参与者信息 (Expert Profile)

- 姓名/ID: [填入]
- AI/编程年限: [例如: 5年]
- 病理项目经验年限: [例如: 2年]
- 开发环境: [例如: vscode, claude code, codex, etc]

### 第一部分: 实验规则 (Rules of Engagement)

1. 目标: 在保证模型性能的前提下, 尽可能快地完成指定任务。
  2. 代码撰写: 可以使用 GitHub Copilot 等AI辅助工具。可以复用你自己以前积累的代码库。
  3. 时间记录: 请记录实验开始到最终完成所需要的时间。
  4. 完成标准 (Definition of Done):
    - 代码无报错运行。
    - 在测试集上输出了指定的指标。
- 

### 任务: CRC-MSI 分类

#### 任务介绍:

These are histological images of colorectal cancer, derived from the TCGA database at <https://portal.cdc.cancer.gov>. Tumor tissue was outlined manually and the tumor region was cut into tiles of 256  $\mu\text{m}$  edge length, saved as 512 px images (effective magnification 0.5  $\mu\text{m}/\text{px}$ ). All image tiles were color-normalized with the Macenko method. Patients were split into training and test set in a 2:1 ratio. For all patients, MSI status was acquired (patients with MSI-H = MSIH; patients with MSI-L and MSS = NonMSIH) and all tiles inherited the label of the parent patient. Then, tiles in the training set were randomly undersampled to equalize classes. The test set was not undersampled.

数据路径: /jhcnas7/Pathology/PathLab\_data\_collection/Data/CRC-MSI

#### 要求:

1. 给出模型在测试集上的性能 (包括, Macro-AUC, weighted-F1, Macro-ACC, ROC 曲线和混淆矩阵)
2. 给出下列两个文件的heatmap可视化结果 (即模型重点关注了哪些地方):

TCGA-QG-A5Z2-01Z-00-DX2.F2352352-8F00-4BB3-8A62-8D1C1E374F95\_(14367,54176).jpg

TCGA-DM-A28G-01Z-00-DX1.5e8602bd-31e1-4813-8214-cd56280defe5\_(10373,34433).jpg

3. 输出模型在测试集上的数据的logits, 并保存为CRC-MSI\_prediciton.csv文件, 文件格式如下:

file\_name, logits\_MSIH,logits\_nonMSIH,label

xx,xx,xxx,xxx

4. 禁止直接使用测试集作为validation
5. 完成下列表格和问卷

实验时间记录表格:

| 阶段<br>(Phase) | 具体动作描述<br>(Actions)                          | 开始时间 | 结束时间 | 净耗时 (分钟) | 备注/痛点<br>(Pain Points)  |
|---------------|----------------------------------------------|------|------|----------|-------------------------|
| 1. 理解与规划      | 阅读数据文档, 构思模型架构, 查找可用库。                       |      |      |          | 例如: 数据格式很乱, 花时间理解了标注文件。 |
| 2. 数据工程       | 编写 Dataset/Dataloader, 处理 WSI 切片/特征加载, 数据增强。 |      |      |          | 例如: 编写多线程加载器花费较多时间。     |
| 3. 模型构建       | 搭建网络结构 (如 ResNet/MIL), 定义 Loss 和 Optimizer。  |      |      |          |                         |
| 4. 训练与调试      | 跑通 Training Loop, 解决 Shape                   |      |      |          | 例如: 维度不匹配, 调试了15分       |

|               |                             |  |  |  |    |
|---------------|-----------------------------|--|--|--|----|
|               | Mismatch<br>等报错<br>(Debug)。 |  |  |  | 钟。 |
| 5. 评估与可视化     | 在测试集推理, 计算指标, 编写绘图代码。       |  |  |  |    |
| 总计<br>(Total) |                             |  |  |  |    |

模型性能结果记录 (Performance Outcome)

| 评估指标<br>(Metric)       | 专家组结果 (Expert Value) | 是否达到 SOTA 水平? (自评) |
|------------------------|----------------------|--------------------|
| AUC (Marco)            | 请填写数值                | 是 / 否              |
| F1-Score<br>(weighted) | 请填写数值                |                    |
| ACC (Macro)            | 请填写数值                |                    |
| 混淆矩阵                   | 请附上可视化的figure        |                    |
| ROC曲线                  | 请附上可视化的曲线            |                    |

专家主观体验反馈 (Qualitative Feedback)

请简短回答以下问题：

- 1. 最耗时的步骤是什么？为什么？
- 2. 为了实现任务的可视化(热力图)，你编写了多少行代码？耗时多久？

3. 如果让你把你的这套代码交给不懂编程的病理医生使用, 你觉得最大的困难是什么?